

خطة العمل الموحدة والتنفيذية لمشروع Machine Learning (Bitext Dataset)

تم دمج كافة التحليلات والخطط التقنية في دليل عمل موحد ومفصل ليكون مرجعاً تنفيذياً شاملاً لجميع أعضاء الفريق، يضمن توزيع الأدوار بوضوح وتطبيق أفضل الممارسات البرمجية من مرحلة إعداد البيئة حتى النشر النهائي.

1. القرارات الهندسية والرؤية الموحدة للمشروع

- طبيعة البيانات والتحديات:
 - الحجم الإجمالي: حوالي 26,000 طلب خدمة عملاء.
 - وجود عدم توازن بين الفئات (Class Imbalance) بنسبة تفوق 6.3:1.
 - وجود 2,237 نص مكرر يحتاج إلى معالجة واستبعاد قبل التقسيم لمنع تسريب البيانات (Data Leakage).
- استراتيجيات معالجة النصوص الذكية (clean_text):
 - الحافظات النصية (Placeholders): فك الأقواس الملثوية مثل تحويل {{Order Number}} إلى order number لأن المحتوى نفسه يحمل دلالة تنبؤية قوية للقسم.
 - الكلمات الشائعة (Stopwords) والنفي: إزالة الكلمات الزائدة مع حماية أدوات النفي (مثل: not, no, never, can't, unable).
 - الأخطاء الإملائية (Typos): الإبقاء عليها وعدم تصحيحها يدوياً، حيث يتم التعامل معها تقنياً عبر ميزات Char N-grams.
- مسارات النمذجة (Pipelines Strategy):
 - Pipeline A (أساسي / Mandatory): الاعتماد على دمج ميزات الكلمات والحروف عبر FeatureUnion لـ Word TF-IDF (1–2 grams) و Char TF-IDF (3–5 grams) مع خوارزميات LinearSVC و LogisticRegression و ComplementNB.
 - Pipeline B (مقارنة / Optional): تدريب Word2Vec وحساب المتوسط الموزون بـ TF-IDF للمتجهات.
 - Pipeline C (متقدم / Optional): إجراء Fine-tuning لـ DistilBERT للمقارنة المباشرة بين Classical ML و Transformers.
- قيود النشر والتسليم:
 - الاعتماد على نماذج Scikit-learn + TF-IDF كـ Baseline رئيسي صفي لخفته وسرعة استجابته وصغر حجمه (أقل من 50MB) للتوافق مع Vercel Serverless Limits.
 - إتاحة Gradio Demo كعرض تفاعلي مباشر للتجربة.

2. الأدوات ومستلزمات البيئة البرمجية (Tech Stack)

المرحلة	الأدوات والمكتبات	الغرض والوظيفة
التهيئة والبيئة	Python 3.x, nltk, gensim, imbalanced-learn	تأسيس بيئة ml_env وتنزيل حزم WordNet للـ Lemmatization.
قراءة وتنظيف البيانات	pandas, numpy, re, string	قراءة ملف CSV، تفريغ الأقواس، إزالة الرموز، وتتبع التكرارات.
استكشاف البيانات (EDA)	matplotlib, seaborn	رسم توزيع الفئات (6.3:1)، أطوال الجمل،

4. توزيع الأدوار ومخرجات التسليم للفريق

المهام والمسؤوليات التفصيلية	المخرج التسليمي الملموس	عضو الفريق / الدور
- تنفيذ Step 1 كشف التكرارات ومعالجة الفجوة 6.3:1. - رسم توزيع الفئات وأطوال النصوص وإحصائيات EDA. - استخراج الرؤى التجارية والـ Insights الخاصة بالشركة.	- قسم EDA بالـ Notebook. - عرض تقديمي للـ Business Insights.	1. Data & EDA Lead
- تطوير دالة Step 2 (clean_text) وحماية الـ Placeholders والـ Negations. - بناء مسار FeatureUnion لـ Word & Char TF-IDF (Step 4). - تدريب نموذج Word2Vec واستخراج المتجهات الموزونة (Step 5).	- ملف الـ Vectorizer المحفوظ tfidf_vectorizer.pkl. - كود المعالجة والـ Feature Engineering.	2. NLP & Preprocessing Lead
- تنفيذ التقسيم الطبقي (Step 3) وإلغاء التكرارات. - تطبيق GridSearchCV وضبط الموديلات الثلاثة بناءً على (Step 4) Macro-F1. - تنفيذ تجربة DistilBERT وتقييم Confusion Matrix (Step 6) و (7).	- ملف الموديل الفائز best_model.pkl. - جدول مقارنة الموديلات (Benchmark Table).	3. ML Modeling & Evaluation Lead
- بناء واجهة تفاعلية بـ Gradio لاختبار التنبؤ المباشر. - بناء API بـ FastAPI أو Flask وتجهيز النشر على Vercel. - ضبط ملفات requirements.txt وإشراف مستودع GitHub.	- رابط Gradio Demo أونلاين. - رابط API فعال على Vercel ورابط GitHub Repo.	4. Deployment & Demo Lead

5. الجدول الزمني للتنفيذ (10 - 12 يوم)

- اليوم 1 - 2: إعداد البيئة البرمجية ml_env واستكشاف البيانات (Step 0 & Step 1).
- اليوم 3 - 4: بناء دالة التنظيف clean_text وإزالة التكرارات والتطبيق الطبقي للتقسيم (Step 2 & Step 3).
- اليوم 5 - 7: تنفيذ FeatureUnion وتدريب النماذج عبر GridSearchCV للـ Pipeline A والـ Word2Vec (Step 4 & Step 5).
- اليوم 8: تجربة DistilBERT واستخراج تقارير التقييم و Confusion Matrix وحفظ النماذج (Step 6 & Step 7).
- اليوم 9 - 10: تطوير واجهة Gradio Demo وبناء الـ API والنشر على Vercel / HuggingFace Spaces.
- اليوم 11 - 12: توثيق مستودع الكود (README)، تجميع الـ Notebook النهائي، والعرض التقديمي للنتيم.

6. (GitHub Repository Structure) الهيكل التنظيمي لمستودع الكود

```
project-root/
├── data/
│   └── bitext_customer_support.csv
├── notebooks/
│   └── text_classification.ipynb # ملف العمل الرئيسي الموحد
├── models/
│   ├── tfidf_vectorizer.pkl      # ملف الـ FeatureUnion (Word + Char)
│   ├── word2vec.model           # (اختياري) نموذج Word2Vec
│   └── best_model.pkl            # LinearSVC الموديل الفائز (عادة)
├── demo/
│   └── app.py                    # واجهة Gradio Demo
├── api/
│   ├── main.py                  # النشر على Vercel (FastAPI)
│   ├── requirements.txt
│   └── vercel.json
└── README.md                    # التوثيق ونتائج مقارنة النماذج
```